

Desenvolvimento de um Controlador Q-Learning para a Navegação Autônoma de um Veículo Seguidor de Faixa^{*}

David Simon Marques^{*}

^{*} *Escola de Engenharia, Universidade Federal de Minas Gerais (e-mail:
davidsimon@ufmg.br)*

Abstract: The development of control systems for autonomous vehicles presents complex challenges related to vehicle dynamics and safety. This paper proposes the implementation of an autonomous *Lane Following* controller based on the Q-Learning Reinforcement Learning algorithm. The problem was modeled as a Markov Decision Process (MDP) with discretized state and action spaces, with training and validation performed in the CARLA simulator (v0.9.16). To optimize convergence and mitigate vehicle inertia during acceleration, a two-phase training strategy based on *Curriculum Learning* was applied, transferring knowledge from low-speed scenarios to high-speed dynamics. The results demonstrate that the agent successfully internalized the navigation policy, remaining within the road boundaries. The lateral oscillations observed in the trajectory validate the inherent limitations of the tabular technique.

Resumo: O desenvolvimento de sistemas de controle para veículos autônomos apresenta desafios complexos relacionados à dinâmica e segurança veicular. Este artigo propõe a implementação de um controlador autônomo de manutenção de faixa baseado no algoritmo de Aprendizado por Reforço Q-Learning. O problema foi modelado como um Processo de Decisão de Markov (MDP) com espaços de estados e ações discretizados, sendo o treinamento e a validação realizados no simulador CARLA (v0.9.16). Para otimizar a convergência e contornar a inércia do veículo em aceleração, aplicou-se uma estratégia de treinamento em duas fases baseada em *Curriculum Learning*, transferindo o conhecimento de cenários de baixa para dinâmicas de alta velocidade. Os resultados demonstram que o agente internalizou com sucesso a política de navegação, mantendo-se dentro dos limites da via. As oscilações laterais observadas na trajetória validam as limitações inerentes da técnica tabular.

Keywords: Reinforcement Learning; Q-Learning; Curriculum Learning; Autonomous Vehicles; CARLA Simulation; Markov Decision Process.

Palavras-chaves: Aprendizado por Reforço; Q-Learning; Curriculum Learning; Veículos Autônomos; Simulação CARLA; Processo de Decisão de Markov.

1. INTRODUÇÃO

A evolução contínua da indústria automotiva e da robótica móvel tem impulsionado o desenvolvimento de Sistemas Avançados de Assistência ao Condutor (*ADAS*), pavimentando o caminho para a direção totalmente autônoma. Nesse cenário, a navegação segura é um requisito fundamental, destacando-se a tarefa de manutenção do veículo em sua faixa de rolamento (*Lane Keeping* ou *Lane Following*). Essa capacidade é essencial não apenas para garantir a segurança dos passageiros e pedestres, mas também para servir como base para manobras mais complexas em ambientes de trânsito dinâmicos e imprevisíveis.

Tradicionalmente, o controle de trajetória é realizado por controladores clássicos, como o PID (Proporcional-Integral-Derivativo). Embora eficientes em muitos cenários, essas abordagens frequentemente exigem um ajuste

manual exaustivo de parâmetros e dependem de modelos matemáticos precisos da dinâmica do veículo (Saadatmand et al., 2020), o que pode se tornar um desafio em condições de pista variáveis. Em contrapartida, algoritmos de Inteligência Artificial e Machine Learning, especificamente aqueles que aprendem com a experiência, oferecem uma alternativa robusta para lidar com ambientes não lineares (Moujahid et al., 2018). Contudo, treinar um agente autônomo no mundo real exige milhares de tentativas, envolvendo riscos inaceitáveis de acidentes e altos custos, o que torna imperativo o uso de simuladores de alta fidelidade para um treinamento seguro e escalável.

Para superar essas limitações, este trabalho propõe a aplicação de Aprendizado por Reforço (*Reinforcement Learning*), utilizando especificamente o algoritmo *Q-Learning* — uma abordagem tabular e livre de modelo (*model-free*) — para o controle autônomo de trajetória. O desafio técnico central desta abordagem consiste em mapear um ambiente contínuo e complexo, que abrange a física do carro e a geometria da via, em um espaço de estados e ações

^{*} Esse artigo foi desenvolvido no contexto de aplicação dos conceitos aprendidos durante a primeira parte do curso de Aprendizado por Reforço (PPGEE - UFMG)

discretas (englobando níveis de aceleração e esterçamento) que o algoritmo consiga processar (Wang et al., 2018). Para viabilizar o treinamento e a validação do controlador, foi utilizado o simulador CARLA, uma plataforma avançada de código aberto amplamente reconhecida por seu realismo na pesquisa de condução autônoma (Gutiérrez-Moreno et al., 2022).

O objetivo geral deste trabalho é desenvolver e avaliar um controlador baseado em Q-Learning capaz de manter um veículo de forma estável em sua faixa de rolamento no simulador. Para alcançar essa meta, definem-se os seguintes objetivos específicos: modelar o problema de Lane Following como um Processo de Decisão de Markov (MDP), estabelecendo a função de recompensa e a discretização coerente de estados e ações; implementar a integração do algoritmo com a API do simulador; treinar o agente explorando diferentes hiperparâmetros e estratégias de aprendizado, como o Curriculum Learning para o incremento gradual de velocidade e, por fim, avaliar o desempenho do controlador em relação à estabilidade da trajetória e à taxa de convergência dos episódios.

O restante deste trabalho está estruturado da seguinte forma: o Capítulo 2 aborda a fundamentação teórica; o Capítulo 3 detalha a metodologia e a configuração do simulador CARLA; o Capítulo 4 discute os resultados do treinamento do agente; e o Capítulo 5 traz as conclusões e diretrizes para trabalhos futuros.

2. FUNDAMENTAÇÃO TEÓRICA

2.1 Aprendizado por Reforço e Q-Learning

Técnicas de aprendizado de máquina têm sido amplamente utilizadas em diversas aplicações. Em Watkins and Dayan (1992) foi apresentado o Q-Learning, consolidando-o como um dos algoritmos de maior destaque no campo do Aprendizado por Reforço (RL - *Reinforcement Learning*). O RL baseia-se fundamentalmente na técnica de aprendizado por Diferença Temporal (TD - *Temporal Difference*), sendo o Q-Learning categorizado por diversos pesquisadores como um caso especial de aprendizado TD *off-policy*.

A regra básica de atualização do algoritmo Q-Learning pode ser expressa por:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right] \quad (1)$$

onde s , a e r representam, respectivamente, o estado, a ação e a recompensa obtida no instante de tempo t , enquanto s' denota o estado subsequente. Além disso, γ , α e $Q(s, a)$ representam o fator de desconto $\gamma \in [0, 1]$ — utilizado para garantir a convergência da função de valor —, a taxa de aprendizado (*learning rate*) e a função de valor no tempo t para o estado s e ação escolhida a , respectivamente.

Na formulação original do Q-Learning, adota-se uma abordagem puramente baseada em exploração (*exploitation*), na qual apenas a política ótima conhecida é seguida. Contudo, esse método pode ser ineficiente e levar à estagnação em mínimos locais. Para contornar esse problema e assegurar exploração (*exploration*) suficiente durante o

aprendizado, o agente precisa ter a permissão de selecionar ações não ótimas.

Como solução, emprega-se a política ϵ -greedy, que permite a escolha de uma ação aleatória com probabilidade ϵ — promovendo a descoberta de novos estados — e da melhor ação disponível na Tabela-Q com probabilidade $1 - \epsilon$. No entanto, manter uma taxa de exploração elevada e constante ao longo de todo o processo prejudica a convergência da política de controle para um comportamento ótimo. Por essa razão, aplica-se um mecanismo de decaimento sobre o parâmetro ϵ ao longo dos episódios, atualizado a cada iteração de acordo com a equação:

$$\epsilon \leftarrow \max(\epsilon_{min}, \epsilon \cdot d) \quad (2)$$

onde $d \in (0, 1)$ representa o fator de decaimento (*decay rate*) e ϵ_{min} é o limite inferior estipulado para garantir uma exploração residual mínima. Essa formulação permite que o modelo priorize a investigação em ambientes desconhecidos nas fases iniciais, transicionando gradualmente para a exploração da política consolidada à medida que o treinamento avança.

2.2 Aprendizado por Currículo

O Aprendizado por Currículo (*Curriculum Learning*) é uma estratégia de treinamento inspirada no processo cognitivo biológico, formalizada no contexto de aprendizado de máquina por Bengio et al. (2009). Em vez de submeter o agente à complexidade máxima do ambiente desde o início do treinamento, o modelo é exposto a uma sequência estruturada de tarefas com dificuldade progressiva. No domínio do Aprendizado por Reforço aplicado ao controle de veículos autônomos, o treinamento direto em altas velocidades pode impor desafios relacionados à inércia mecânica e à necessidade de respostas de esterçamento em janelas de tempo curtas.

A aplicação do *Curriculum Learning* permite mitigar esse obstáculo iniciando o treinamento em velocidades reduzidas, um cenário no qual o mapeamento das ações para manter o alinhamento da faixa é mais tolerante a erros. Após o agente consolidar uma Tabela-Q base e robusta, esse conhecimento empírico prévio é preservado e utilizado como ponto de partida para novos ciclos de treinamento, nos quais os limites de velocidade são gradativamente incrementados e a taxa de exploração (ϵ) é ajustada para valores mais moderados. Essa transição metodológica serve para estabilizar o aprendizado, permitindo que o controlador faça adaptações finas aos novos comportamentos inerciais sem a necessidade de reaprender os fundamentos básicos da navegação, resultando em uma política final mais performática e segura.

3. METODOLOGIA

3.1 Ambiente de Simulação

Para o treinamento e validação do controlador proposto, utilizou-se o simulador de código aberto CARLA (*Car Learning to Act*) em sua versão 0.9.16 (Dosovitskiy et al., 2017). Ele foi selecionado por fornecer um ambiente de alta fidelidade física e visual, permitindo a simulação de dinâmicas veiculares complexas e a extração de dados precisos do ambiente através de sua API em Python.

O agente de controle foi implementado em um veículo do modelo *Tesla Model 3*, selecionado por representar um padrão de dinâmica de veículos elétricos modernos. Para garantir a robustez e a generalização do aprendizado do modelo, o veículo é posicionado no mapa através de um ponto de partida (*spawn point*) selecionado aleatoriamente a cada novo episódio de treinamento, dentre o conjunto de localizações pré-definidas disponibilizadas pelo mapa do simulador.

A percepção do ambiente para a tarefa de *lane following* fundamenta-se no sistema de *waypoints* do CARLA. Estes *waypoints* são referências de posição absolutas que indicam o centro das faixas de rolamento, permitindo que o controlador calcule, em tempo real, o erro de deslocamento lateral (*lane offset*) e o erro de orientação (*heading error*) em relação à trajetória ideal.

A atuação sobre o veículo é realizada por meio de comandos básicos típicos da condução, são eles:

- **Esterçamento (*steer*):** Um valor escalar no intervalo $[-1.0, 1.0]$, em que valores positivos indicam uma curva para a direita e valores negativos para a esquerda.
- **Aceleração (*throttle*):** Um valor escalar contínuo no intervalo $[0.0, 1.0]$, que define a intensidade da pressão no acelerador do veículo.
- **Frenagem (*brake*):** O simulador disponibiliza o controle de frenagem através de um valor escalar no intervalo $[0.0, 1.0]$. Contudo, por se tratar de uma simulação simplificada operando em baixas velocidades, optou-se por manter a frenagem no espaço de ações do agente com valor nulo, sendo a desaceleração passiva suficiente para a manutenção da estabilidade do veículo.

A percepção via *waypoints* e a atuação por meio de comandos de direção e aceleração compõem a base para a modelagem do espaço de estados e ações do algoritmo Q-Learning detalhado a seguir.

3.2 Configuração do Experimento e Hiperparâmetros

Para aplicar o algoritmo Q-Learning ao problema de controle autônomo, a tarefa de navegação foi formalizada como um Processo de Decisão de Markov (MDP), definido pela interação contínua entre o espaço de estados, o conjunto de ações e a função de recompensa. Inicialmente, o espaço de observações contínuas gerado pelo simulador foi transformado em um espaço discreto e finito por meio de um processo de *binning*. Essa discretização é uma etapa crucial para viabilizar o uso estrutural da Tabela-Q, evitando a explosão de dimensionalidade. Foram estabelecidos limiares específicos para três variáveis de estado primárias: o erro de deslocamento lateral (*lane offset*) subdividido nos limiares $[-0.5, -0.2, 0.0, 0.2, 0.5]$ metros; o erro de orientação (*heading error*) mapeado em $[-0.4, -0.2, 0.0, 0.2, 0.4]$ radianos; e a velocidade escalar em $[2.0, 4.0, 6.0, 8.0, 10.0]$ m/s.

Quanto ao espaço de atuação, o controlador foi modelado para operar sobre um conjunto discreto de sete ações predefinidas, que definem os comandos de esterçamento (*steer*) e aceleração (*throttle*). O mapeamento de ações inclui: comandos de curva máxima (esterçamento de -1.0

e 1.0) são executados com aceleração conservadora (0.1), enquanto a estabilidade em linha reta (esterçamento 0.0) permite a aceleração máxima do conjunto (0.5). As opções intermediárias fornecem ajustes leves e moderados, garantindo ao agente a granularidade necessária para corrigir desvios de trajetória, evitando instabilidade inercial ou derrapagens. O comando de frenagem foi mantido nulo em todas as ações, delegando a redução de velocidade à desaceleração passiva do motor.

Para guiar a convergência da política de controle, a função de recompensa foi estruturada sob cinco frentes. A componente principal promove a centralização do veículo, concedendo uma recompensa máxima de 1.0 no centro exato da via e aplicando um decaimento linear até 0.0 nas extremidades marginais (limite de 2.0 metros). Atuando em conjunto com a centralização, introduziu-se uma penalidade contínua proporcional ao erro de direção (*heading error*), que deduz valores da recompensa com base no desvio angular do veículo, mitigando comportamentos oscilatórios e promovendo um alinhamento mais suave à rota. Além disso, foi definido um bônus de velocidade para encorajar a progressão fluida da viagem, calculado de forma proporcional até um limite máximo de referência de 10.0 m/s (≈ 36 km/h), o que desencoraja o agente de explorar brechas no sistema que premiam o avanço excessivamente lento. Em relação às condições de término de episódio, aplicou-se uma penalidade restritiva de -10.0 caso o veículo saia da pista (*offroad*), enquanto o cumprimento completo e seguro do percurso é bonificado com um acréscimo final de $+5.0$ pontos.

O diagrama de blocos que demonstra o funcionamento dessa modelagem para o treinamento é apresentado na Figura 1.




Figura 1. Diagrama da arquitetura de Aprendizado por Reforço, ilustrando o fluxo contínuo de observação, ação e recompensa entre o agente e o ambiente simulado.

Além dos parâmetros do algoritmo, definiu-se também uma distância contínua percorrida de 2.000 metros sem

infrações de pista como o critério de sucesso do episódio. A Tabela 1 sumariza os valores adotados.

Tabela 1. Hiperparâmetros e Configurações do Treinamento

Parâmetro	Valor
Total de Episódios	3.000
Taxa de Aprendizado (α)	0,05
Fator de Desconto (γ)	0,99
Exploração Inicial (ϵ)	0,3
Taxa de Decaimento do ϵ	0,995
Exploração Mínima (ϵ_{min})	0,01

Por fim, a infraestrutura do código foi concebida para suportar a estratégia de *Curriculum Learning*. Por meio de mecanismos de salvamento e carregamento da Tabela-Q consolidada (*load_pretrained*), o sistema permite que agentes treinados inicialmente em velocidades reduzidas tenham sua base de conhecimento importada para novos ciclos. Nestes ciclos de refinamento, ajustes manuais pontuais no limiar de velocidade e na taxa de exploração promovem uma adaptação à dinâmica inercial mais severa, sem a perda dos comportamentos elementares de condução previamente adquiridos.

4. RESULTADOS E DISCUSSÕES

4.1 Análise do Treinamento Inicial

O desempenho do agente durante a fase primária de treinamento foi avaliado por meio do monitoramento contínuo de algumas métricas fundamentais ao longo de 3.000 episódios, dentre elas: a recompensa total por episódio, o desvio médio em relação ao centro da faixa (*lane offset*) e a distância média percorrida. Os resultados gráficos evidenciam a curva de aprendizado característica de algoritmos baseados em Q-Learning aplicados a ambientes de simulação contínua.

A análise da progressão da recompensa (Figura 2) revela que os episódios iniciais foram marcados por retornos acumulados, com picos de punição e recompensa. Esse comportamento é uma consequência direta da alta taxa de exploração estipulada no início do treinamento ($\epsilon = 0.3$), momento em que o agente adota ações predominantemente aleatórias para mapear o espaço de estados. À medida que o fator de exploração decai e a Tabela-Q é populada com transições de estado viáveis, observa-se uma tendência de ascensão e estabilização na curva de média móvel (em vermelho), indicando que o modelo superou a fase exploratória e começou a priorizar a exploração de ações seguras.

A evolução física do comportamento do veículo corrobora o aumento das recompensas numéricas. O gráfico de Desvio Médio da Faixa (Figura 3) demonstra que o agente inicia o treinamento com instabilidade lateral significativa, afastando-se em média mais de 1,6 metros do centro da via. Contudo, impulsionado pela função de recompensa que penaliza o afastamento das bordas, o controlador reduz esse erro. Após os primeiros milhares de episódios de maior turbulência, a média móvel do desvio lateral despenca e estabiliza em patamares substancialmente menores, provando que a política aprendida conseguiu associar de forma




Figura 2. Evolução da recompensa total acumulada ao longo de 3.000 episódios de treinamento. A curva em azul representa os dados brutos de cada iteração, enquanto a linha vermelha representa a média móvel.

eficaz o conjunto de ações de esterçamento à manutenção do veículo próximo aos *waypoints*.




Figura 3. Redução do erro de deslocamento lateral (*lane offset*) ao longo dos episódios, evidenciando o aumento da estabilidade do veículo no centro da faixa.

Por fim, a eficácia da centralização reflete-se diretamente na sobrevivência do agente no ambiente simulado. O gráfico de dados não filtrados de distância média percorrida (Figura 4) exibe um crescimento estrutural correlacionado à diminuição do desvio lateral, resultado, ao final, em uma taxa de acerto de 41,3%. Inicialmente incapaz de percorrer percursos longos antes de invadir as margens da via, o veículo gradativamente estende seu tempo de operação contínua e sua progressão no mapa. A variância residual observada nos episódios finais é inerente à natureza tabular do controlador adotado, que, ao operar com hiperparâmetros rígidos e ações restritas de condução, ocasionalmente enfrenta estados mais complexos.

Por fim, o balanço desta primeira fase atesta a viabilidade da modelagem MDP proposta, estabelecendo a maturidade cognitiva necessária para a etapa seguinte de *Curriculum Learning* em velocidades maiores.

4.2 Impacto do Aprendizado por Currículo

Para avaliar a eficácia da transferência de conhecimento e da estratégia de *Curriculum Learning*, os 3.000 episódios da fase de refinamento foram comparados em relação aos dados da fase de exploração inicial. Os gráficos comparativos evidenciam a complexa dinâmica de *trade-off* que ocorre quando um agente treinado para estabilidade é exposto a exigências dinâmicas mais agressivas.




Figura 4. Evolução da distância percorrida por episódio. A tendência de alta confirma o aumento progressivo da capacidade de sobrevivência do agente no ambiente simulado.

O objetivo primário desta segunda fase foi atingido com sucesso, conforme demonstrado no gráfico de Velocidade Média (Figura 5). A adoção do novo mapeamento de ações (com *throttles* superiores) e a elevação da bonificação de velocidade para 1,8 induziram o agente a alterar seu comportamento conservador. Observa-se um salto imediato e sustentado na velocidade média de operação, provando que a Tabela-Q herdada foi capaz de incorporar os novos comandos de aceleração sem colapsar a política de condução básica.




Figura 5. Evolução da velocidade média nos dois ciclos de treinamento, destacando o aumento de velocidade operacional alcançado na fase de refinamento.

Entretanto, esse ganho de velocidade impôs desafios mecânicos e algorítmicos evidentes. O gráfico de Erro Médio de Direção (Figura 6) revela que, durante a fase de refinamento, o desvio angular e o afastamento do centro da faixa operaram em patamares superiores aos observados no fim da primeira fase. Esse fenômeno poderia ser explicado pela tentativa do agente de maximizar a nova função de recompensa: tentando manter a velocidade alta e capturar o bônus de 1,8, o controlador aprendeu a sacrificar o alinhamento perfeito, adotando trajetórias de curva mais abertas para mitigar a perda de inércia, resultando em um erro de rastreamento de faixa estatisticamente maior, porém ainda dentro dos limites seguros da via.

A distância média percorrida (Figura 7) e a taxa geral de sucesso sofreram uma redução durante este ciclo de treinamento. Essa queda não indica um "esquecimento", mas sim o impacto da física do simulador combinada à taxa de exploração. Ao reiniciar o parâmetro ϵ para 0,1 com o intuito de adaptar os estados às novas velocidades, o agente voltou a tomar ações aleatórias em 10% das decisões




Figura 6. Comparativo da distância percorrida por episódio, demonstrando a redução temporária da taxa de sobrevivência gerada pela adaptação do veículo à nova inércia em altas velocidades.

iniciais. Em baixas velocidades, um esterçamento aleatório acentuado resulta em uma correção recuperável; em altas velocidades, o acréscimo inercial reduz drasticamente a janela de tempo de reação, transformando pequenas explorações em saídas de pista.




Figura 7. Comparativo da distância percorrida por episódio, demonstrando a redução temporária da taxa de sobrevivência gerada pela adaptação do veículo à nova inércia em altas velocidades.

Apesar das estatísticas médias de treinamento serem numericamente penalizadas pelas falhas exploratórias geradas pela inércia, a convergência final do modelo em testes finais reflete um controlador capaz de operar satisfatoriamente. A política final (*greedy*) consolidada demonstrou ser capaz de manter o veículo na pista em velocidades maiores, validando o *Curriculum Learning* como uma técnica útil para superar a complexidade física na condução autônoma por método tabular.

4.3 Avaliação Global de Desempenho do Controlador

Para consolidar os resultados do treinamento e avaliar a prontidão do sistema, o modelo final foi submetido a testes de validação utilizando somente a política já consolidada. Nesta etapa, o parâmetro de exploração foi zerado ($\epsilon = 0$), garantindo que o agente tomasse decisões estritamente baseadas nos valores máximos da Tabela-Q. Esse procedimento isola as falhas provocadas intencionalmente pela aleatoriedade exploratória, revelando a verdadeira capacidade de navegação autônoma adquirida.

A política de controle demonstrou-se eficaz para percorrer o espaço da pista. A Figura 8 ilustra o caminho percorrido pelo agente sobreposto à malha viária do simulador

CARLA durante um episódio de validação bem-sucedido. Vale ressaltar que o controlador conseguiu manter o *Tesla Model 3* de forma consistente dentro dos limites da faixa de rolamento. Observa-se, contudo, a presença de oscilações laterais perceptíveis ao longo da simulação. Este comportamento oscilatório é inerente à modelagem adotada. Ele é uma consequência direta da restrição matemática imposta pelo Q-Learning tabular, que exige a discretização dos estados contínuos observados (perda de granularidade sensorial) e a limitação dos comandos de controle a um conjunto reduzido e finito de ações.




Figura 8. Caminho percorrido pelo veículo em teste realizado após as 2 etapas de treinamento. O ponto em verde indica a posição de partida, enquanto o ponto vermelho indica a posição final ao completar 2000m percorridos.

Em complemento à validação do caminho, o comportamento dinâmico do agente reflete o aprendizado consolidado durante a fase de *Curriculum Learning*. Conforme demonstrado na Figura 9, o veículo opera de forma autônoma otimizando a função de recompensa multicritério: mantém um regime de velocidade elevado, ao mesmo tempo em que administra bem o estereçamento para evitar as punições críticas de fuga da faixa.

Em suma, os dados comprovam a validade da abordagem metodológica proposta. A modelagem do controle veicular como um Processo de Decisão de Markov (MDP), aliada à técnica tabular do Q-Learning e ao refinamento progressivo por currículo, demonstrou ser computacionalmente viável e funcional. Embora a natureza puramente discreta do algoritmo imponha limitações inerentes à suavidade dos comandos de direção — quando comparada a abordagens contínuas ou de aprendizado profundo —, o controlador desenvolvido cumpriu o objetivo de manutenção autônoma de faixa (*Lane Following*) sob as dinâmicas físicas realistas do simulador.

5. CONCLUSÃO

Este trabalho apresentou a implementação de um controlador de manutenção de faixa (*Lane Following*) funda-




Figura 9. Resultados de desempenho do controlador em teste de validação. a) Análise de controle mostrando o desvio lateral da faixa (m) e o erro de direção (graus) ao longo do tempo. b) Velocidade do veículo (km/h) em função do tempo

mentado no algoritmo Q-Learning e validado no simulador CARLA 0.9.16. A estratégia de refinamento baseada em *Curriculum Learning* demonstrou ser eficaz para a transição de regimes de baixa velocidade para velocidades superiores, permitindo que o agente adaptasse sua base de conhecimento inercial sem comprometer a política de navegação básica. Embora o modelo tenha alcançado os objetivos de autonomia, observou-se a presença de oscilações na trajetória, atribuídas às restrições da abordagem tabular e à necessidade de discretização dos estados e ações. O repositório completo com o código-fonte está disponível no GitHub¹ e os vídeos com os resultados obtidos podem ser visualizados no OneDrive².

Como trabalho futuro, propõe-se a evolução do sistema por meio do uso de métodos de aprendizado por reforço baseados em aproximação de funções, como o *Deep Q-Network* (DQN). A transição para uma arquitetura de redes neurais oferece vantagens críticas, como a capacidade de processar espaços de estados e ações contínuos, eliminando as limitações impostas pela discretização. Além disso, a melhor generalização para cenários inéditos e a suavização das respostas de controle tendem a mitigar as oscilações observadas, aproximando o comportamento do agente de uma condução humana fluida e segura.

¹ <https://github.com/davidsimonmarques/Q-lane-follower>

² Cole no navegador: https://1drv.ms/v/c/bacbbaced9b1b624/IQAKXDBYQrDCSJ_SWKG8Y7tDAZyKxOmXzhQXrRWMbShVSn4?e=GPqG8i.

REFERÊNCIAS

- Bengio, Y., Louradour, J., Collobert, R., and Weston, J. (2009). Curriculum learning. In *Proceedings of the 26th annual international conference on machine learning*, 41–48.
- Dosovitskiy, A., Ros, G., Codevilla, F., Lopez, A., and Koltun, V. (2017). CARLA: An open urban driving simulator. In *Proceedings of the 1st Annual Conference on Robot Learning*, 1–16.
- Gutiérrez-Moreno, R., Barea, R., López-Guillén, E., Araluce, J., and Bergasa, L.M. (2022). Reinforcement learning-based autonomous driving at intersections in carla simulator. *Sensors*, 22(21). doi:10.3390/s22218373. URL <https://www.mdpi.com/1424-8220/22/21/8373>.
- Moujahid, A., ElAraki Tantaoui, M., Hina, M.D., Soukane, A., Ortalda, A., ElKhadimi, A., and Ramdane-Cherif, A. (2018). Machine learning techniques in adas: A review. In *2018 International Conference on Advances in Computing and Communication Engineering (ICACCE)*, 235–242. doi:10.1109/ICACCE.2018.8441758.
- Saadatmand, S., Azizi, S., Kavousi, M., and Wunsch, D. (2020). Autonomous control of a line follower robot using a q-learning controller. In *2020 10th Annual Computing and Communication Workshop and Conference (CCWC)*, 0556–0561. IEEE.
- Wang, P., Chan, C.Y., and de La Fortelle, A. (2018). A reinforcement learning based approach for automated lane change maneuvers. In *2018 IEEE intelligent vehicles symposium (IV)*, 1379–1384. IEEE.
- Watkins, C.J. and Dayan, P. (1992). Q-learning. *Machine learning*, 8(3), 279–292.